

PROJET 10

OPENCLASSROOMS: FORMATION INGÉNIEUR DATA

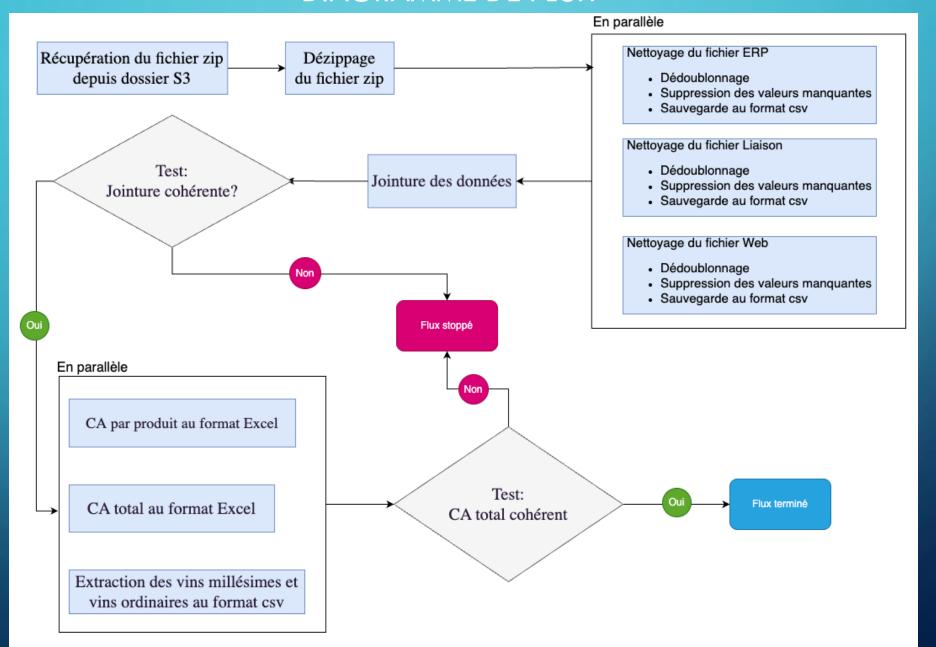
Contexte:

Data Engineer dans l'entreprise BottleNeck, un marchand de vin prestigieux.

But du projet:

Automatiser une chaîne de traitement et d'analyse de données.

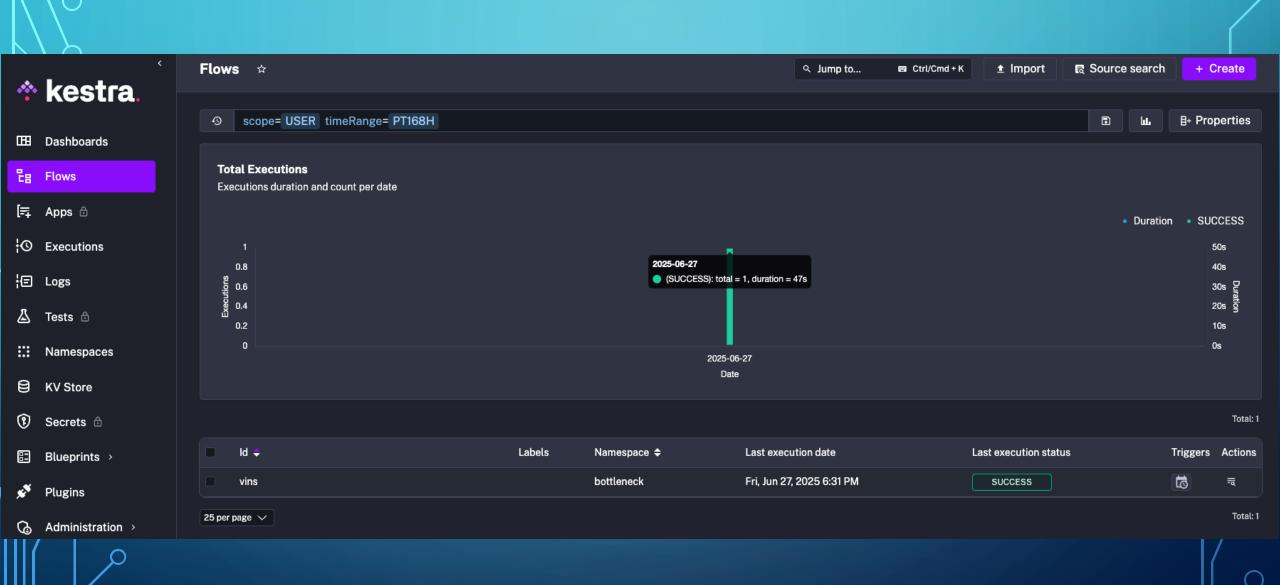
DIAGRAMME DE FLUX



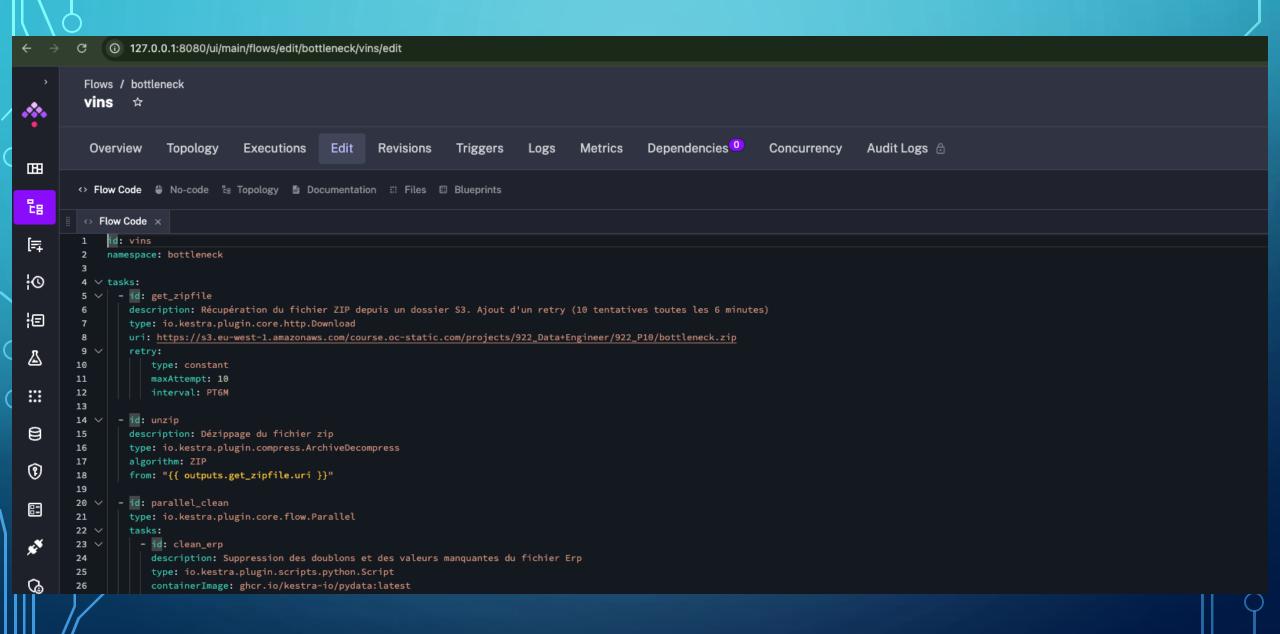
INSTALLATION DE KESTRA

```
[(base) nicolas@Mac-Nicolas Kestra % docker logs kestra
                                org.flywaydb.core.FlywayExecutor Database: jdbc:postgresql://postgres:5432/kestra (PostgreSQL 17.5)
19:28:11.650 INFO main
19:28:11.144 INFO main
                                o.f.core.internal.command.DbValidate Successfully validated 36 migrations (execution time 00:00.023s)
19:28:11.499 INFO main
                                o.f.core.internal.command.DbMigrate Current version of schema "public": 1.38
                                o.f.core.internal.command.DbMigrate Schema "public" is up to date. No migration necessary.
19:28:11.486 INFO
                  main
19:28:12.507 INFO main
                                i.kestra.core.plugins.PluginScanner Registered 99 core plugins (scan done in 81ms)
                                io.kestra.cli.AbstractCommand Starting Kestra 0.23.3 with environments [cli] [revision 1fb7943 / 2025-06-24T15:33]
19:28:12.439 INFO standalone
                               i.kestra.core.plugins.PluginScanner Registered 637 plugins from 109 groups (scan done in 362ms)
19:28:13.175 INFO standalone
19:28:13.533 INFO standalone
                               io.kestra.cli.AbstractCommand Server Running: http://62c4241d014a:8080, Management server on port http://62c4241d014a:8081/health
```

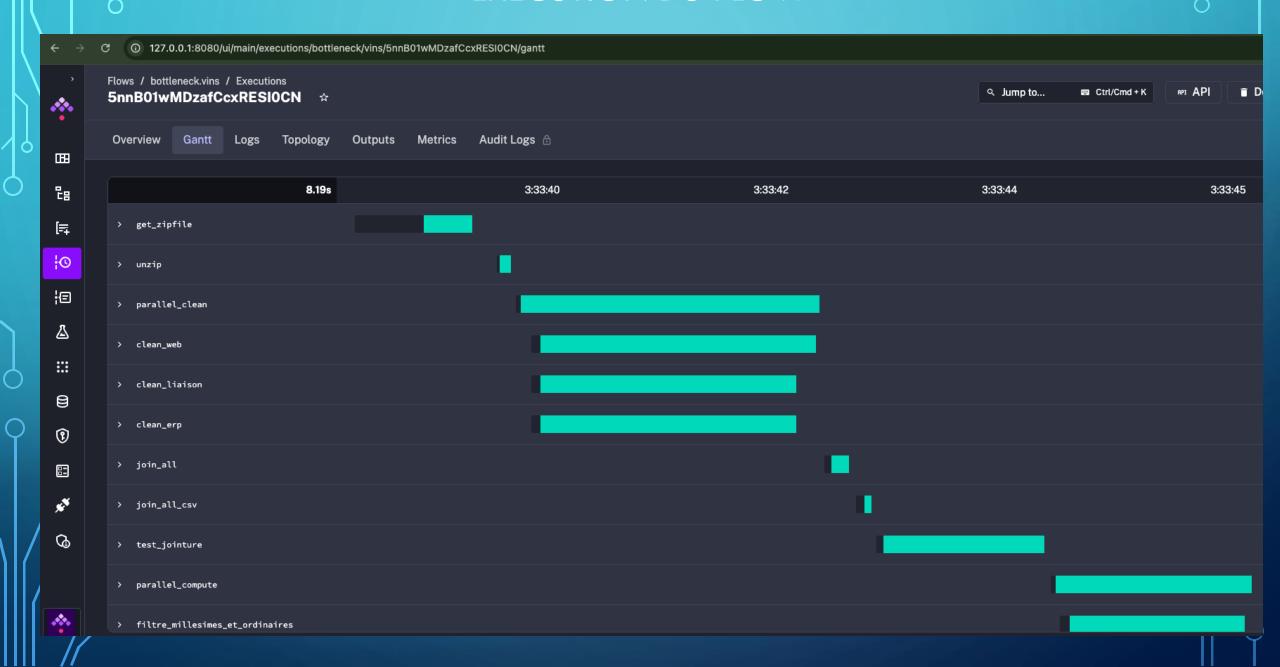
INSTALLATION DE KESTRA



ÉDITION DU FLOW



ÉXECUTION DU FLOW

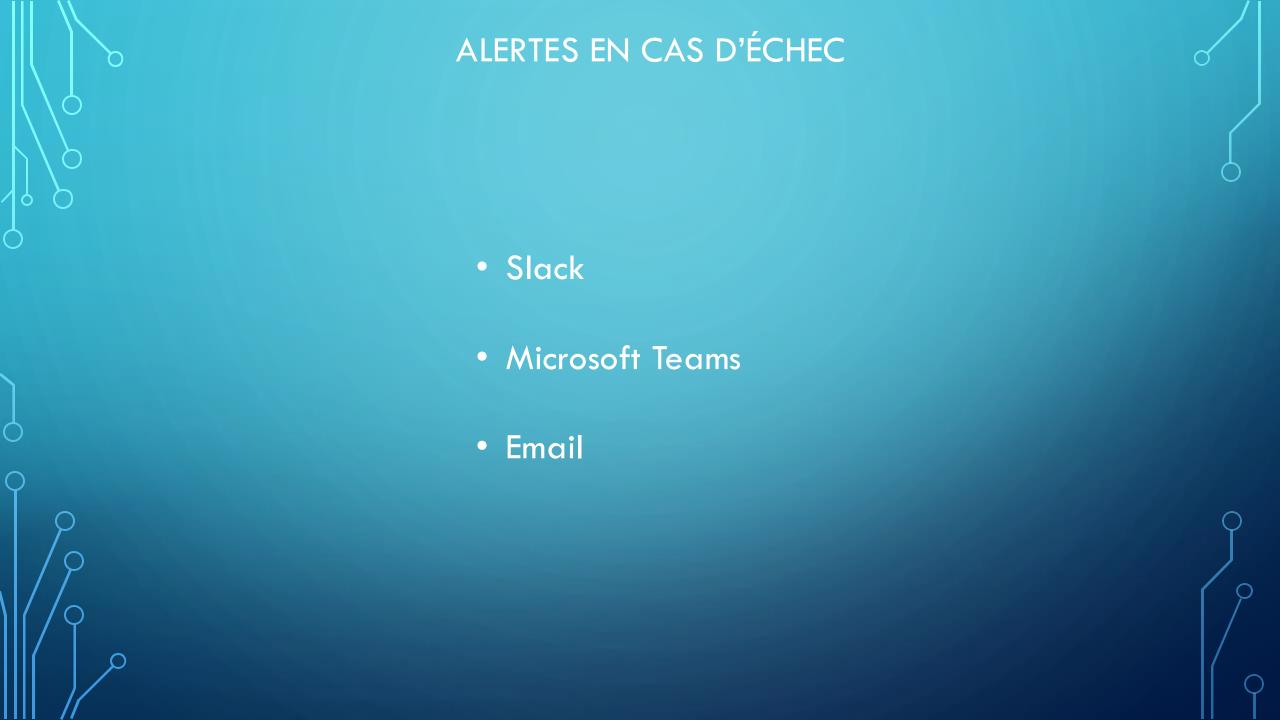


NÉTTOYAGE DES DONNÉES

- Utilisation de python et pandas
- Suppression des doublons et des valeurs manquantes sur chacun des fichiers Erp, Web et Liaison

TESTS SPÉCIFIQUES

- Utilisation de python et pandas
- Test de cohérence de la jointure: le nombre de lignes entre le ficher WEB et la jointure doit être identique
- Test de cohérence du chiffre d'affaires total: compris entre 10000 et 100000 euros





POUR ALLER PLUS LOIN

 Pour de plus gros projets, placer les scripts python sur GITHUB

=> allègement du fichier yaml

• Placer les fichiers csv et excel dans un bucket S3